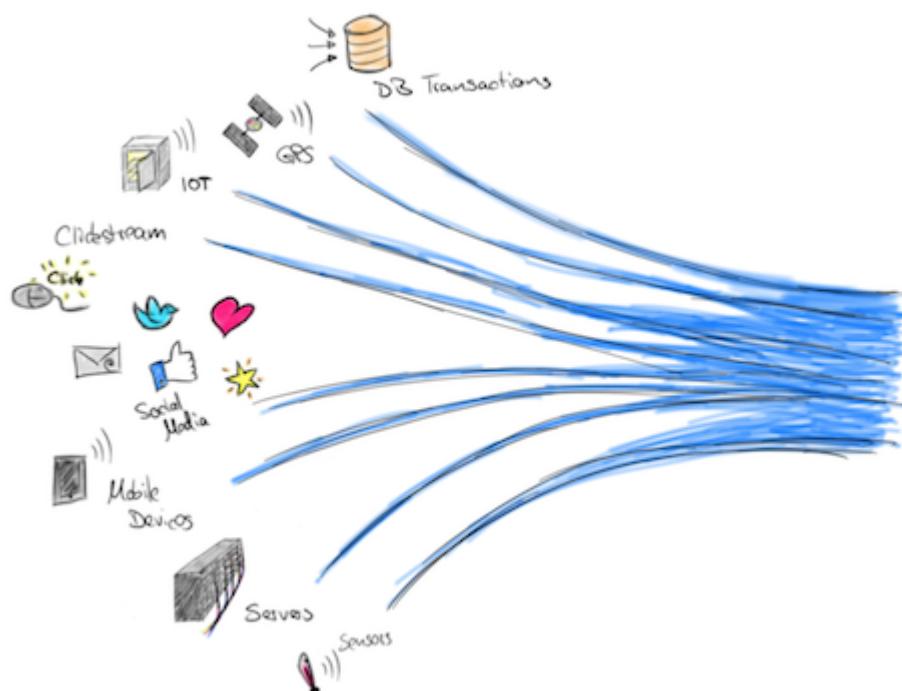


TP2 - Traitement par Lot et Streaming avec Spark



Télécharger PDF



[../tp2.pdf]

Objectifs du TP

Utilisation de Spark pour réaliser des traitements par lot et des traitements en streaming.

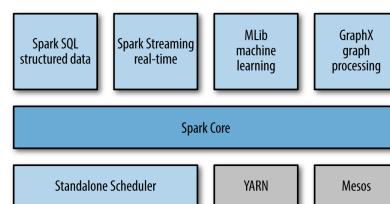
Outils et Versions

- [Apache Hadoop](http://hadoop.apache.org/) [http://hadoop.apache.org/] Version: 2.7.2
- [Apache Spark](https://spark.apache.org/) [https://spark.apache.org/] Version: 2.2.1
- [Docker](https://www.docker.com/) [https://www.docker.com/] Version 17.09.1
- [IntelliJ IDEA](https://www.jetbrains.com/idea/download/) [https://www.jetbrains.com/idea/download/] Version Ultimate 2016.1 (ou tout autre IDE de votre choix)
- [Java](http://www.oracle.com/technetwork/java/javase/downloads/index.html) [http://www.oracle.com/technetwork/java/javase/downloads/index.html] Version 1.8
- Unix-like ou Unix-based Systems (Divers Linux et MacOS)

Spark

Présentation

[Spark](https://spark.apache.org/) [https://spark.apache.org/] est un système de traitement rapide et parallèle. Il fournit des APIs de haut niveau en Java, Scala, Python et R, et un moteur optimisé qui supporte l'exécution des graphes. Il supporte également un ensemble d'outils de haut niveau tels que [Spark SQL](https://spark.apache.org/docs/latest/sql-programming-guide.html) [https://spark.apache.org/docs/latest/sql-programming-guide.html] pour le support du traitement de données structurées, [MLlib](https://spark.apache.org/docs/latest/ml-guide.html) [https://spark.apache.org/docs/latest/ml-guide.html] pour l'apprentissage des données, [GraphX](https://spark.apache.org/docs/latest/graphx-programming-guide.html) [https://spark.apache.org/docs/latest/graphx-programming-guide.html] pour le traitement des graphes, et [Spark Streaming](https://spark.apache.org/docs/latest/streaming-programming-guide.html) [https://spark.apache.org/docs/latest/streaming-programming-guide.html] pour le traitment des données en streaming.



Spark et Hadoop

Spark peut s'exécuter sur plusieurs plateformes: Hadoop, Mesos, en standalone ou sur le cloud. Il peut également accéder diverses sources de données, comme HDFS, Cassandra, HBase et S3.

Dans ce TP, nous allons exécuter Spark sur Hadoop YARN. YARN s'occupera ainsi de la gestion des ressources pour le déclenchement et l'exécution des Jobs Spark.

Installation

Nous avons procédé à l'installation de Spark sur le cluster Hadoop utilisé dans le [TP1](#) [../tp1/index.html]. Voici les étapes nécessaires pour le lancer:

1. Cloner le repo github contenant les fichiers nécessaires pour le lancement des conteneurs et leur configuration:

```
git clone https://github.com/liliasfaxy/hadoop-cluster-docker
```

2. Construire l'image Docker à partir du fichier Dockerfile fourni.

```
cd hadoop-cluster-docker  
./build-image.sh
```

3. Démarrer les trois conteneurs:

```
sudo ./start-container.sh
```

Le résultat de cette exécution sera le suivant:

```
start hadoop-master container...  
start hadoop-slave1 container...  
start hadoop-slave2 container...  
root@hadoop-master:~#
```

4. Lancer les démons yarn et hdfs en lançant:

```
./start-hadoop.sh
```

Vous pourrez vérifier que tous les démons sont lancés en tapant: `jps`. Un résultat semblable au suivant pourra être visible:

```
880 Jps  
257 NameNode  
613 ResourceManager  
456 SecondaryNameNode
```

La même opération sur les noeuds esclaves (auquels vous accédez à partir de votre machine hôte en tapant `docker exec -it hadoop-slave1 bash`) devrait donner:

```
176 NodeManager  
65 DataNode  
311 Jps
```

Test de Spark avec Spark-Shell

Dans le but de tester l'exécution de spark, commencer par créer un fichier `file1.txt` dans votre noeud master, contenant le texte suivant:

```
Hello Spark Wordcount!  
Hello Hadoop Also :)
```

Charger ensuite ce fichier dans HDFS:

```
hadoop fs -put file1.txt
```

Pour vérifier que spark est bien installé, taper la commande suivante:

spark-shell

Vous devriez avoir un résultat semblable au suivant:

Welcome to

/ \ / . \ , / / / \ \ version 2.2.0
/ \ /

Using Scala version 2.11.8 (OpenJDK 64-Bit Server VM, Java 1.8.0_151)
Type in expressions to have them evaluated.
Type :help for more information.

scala>

Vous pourrez tester spark avec un code scala simple comme suit (à exécuter ligne par ligne):

```
val lines = sc.textFile("file1.txt")
val words = lines.flatMap(_.split("\\s+"))
val wc = words.map(w => (w, 1)).reduceByKey(_ + _)
wc.saveAsTextFile("file1.count")
```

Ce code vient de (1) charger le fichier `file1.txt` de HDFS, (2) séparer les mots selon les caractères d'espacement, (3) appliquer un *map* sur les mots obtenus qui produit le couple (*mot*, 1), puis un *reduce* qui permet de faire la somme des 1 des mots identiques.

Pour afficher le résultat, sortir de spark-shell en cliquant sur *Ctrl-C*. Télécharger ensuite le répertoire *file1.count* créé dans HDFS comme suit:

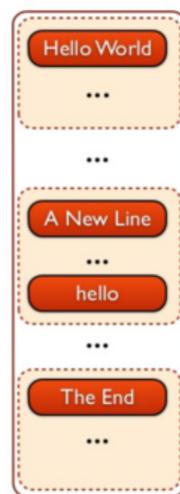
```
hadoop fs -get file1.count
```

Le contenu des deux fichiers *part-00000* et *part-00001* ressemble à ce qui suit:

```
root@hadoop-master:~/file1.count# cat part-00000
(Hello,2)
(Wordcount!,1)
root@hadoop-master:~/file1.count# cat part-00001
(Spark,1)
(:,1)
(Also,1)
(Hadoop,1)
```

L'API de Spark

A un haut niveau d'abstraction, chaque application Spark consiste en un programme *driver* qui exécute la fonction *main* de l'utilisateur et lance plusieurs opérations parallèles sur le cluster. L'abstraction principale fournie par Spark est un RDD (*Resilient Distributed Dataset*), qui représente une collection d'éléments partitionnés à travers les noeuds du cluster, et sur lesquelles on peut opérer en parallèle. Les RDDs sont créés à partir d'un fichier dans HDFS par exemple, puis le transforment. Les utilisateurs peuvent demander à Spark de sauvegarder un RDD en mémoire, lui permettant ainsi d'être réutilisé efficacement à travers plusieurs opérations parallèles.



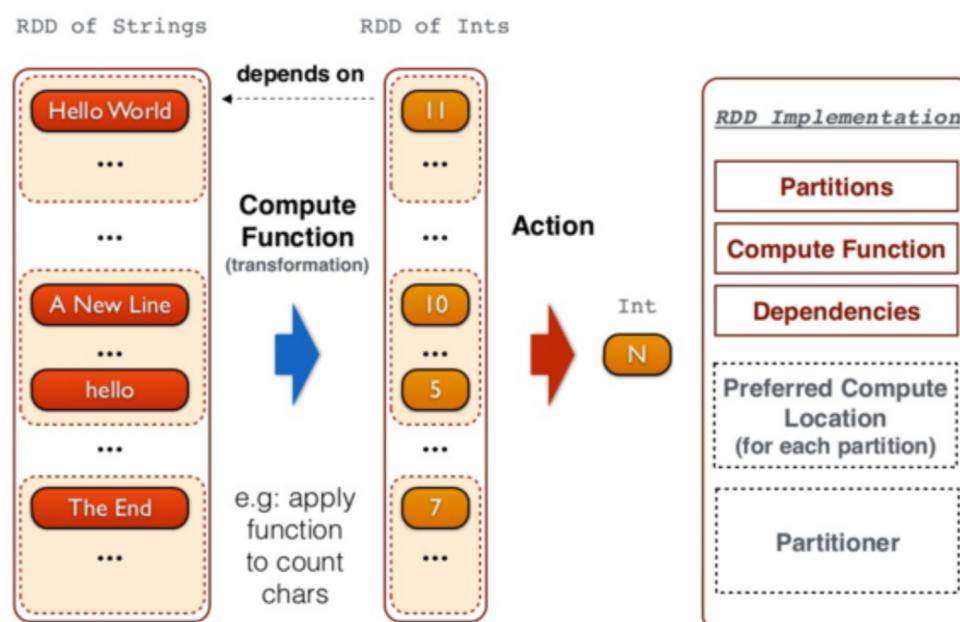
Les RDDs supportent deux types d'opérations:

- les *transformations*, qui permettent de créer un nouveau Dataset à partir d'un Dataset existant

- les *actions*, qui retournent une valeur au programme *driver* après avoir exécuté un calcul sur le Dataset.

Par exemple, un *map* est une transformation qui passe chaque élément du dataset via une fonction, et retourne un nouvel RDD représentant les résultats. Un *reduce* est une action qui agrège tous les éléments du RDD en utilisant une certaine fonction et retourne le résultat final au programme.

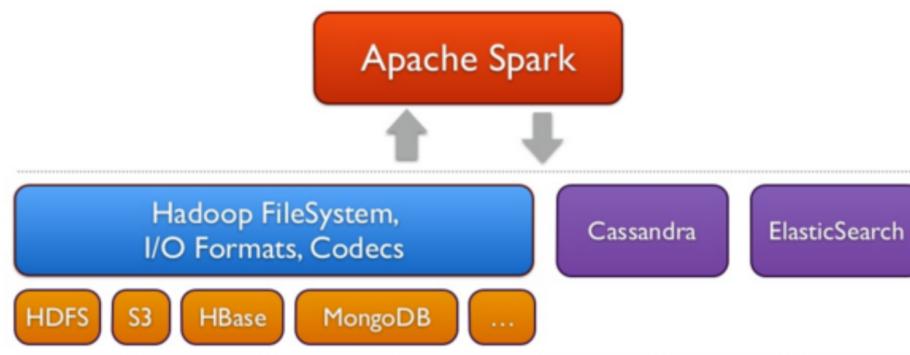
Toutes les transformations dans Spark sont *lazy*, car elles ne calculent pas le résultat immédiatement. Elles se souviennent des transformations appliquées à un dataset de base (par ex. un fichier). Les transformations ne sont calculées que quand une action nécessite qu'un résultat soit retourné au programme principal. Cela permet à Spark de s'exécuter plus efficacement.



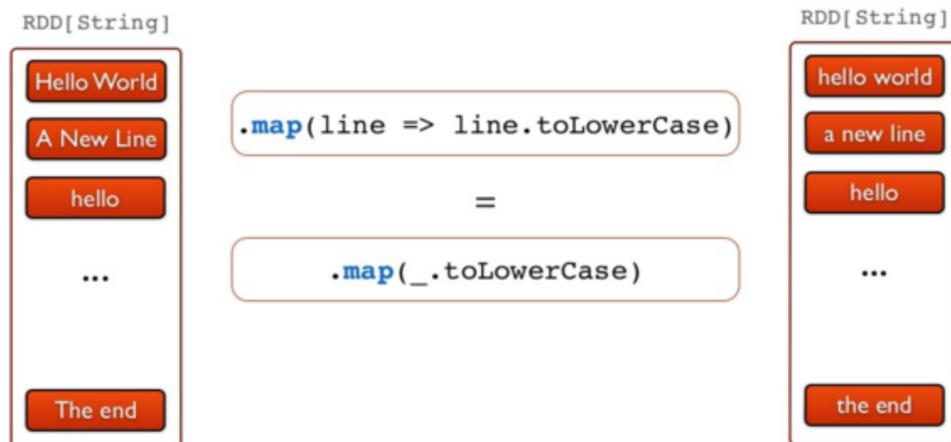
Exemple

L'exemple que nous allons présenter ici par étapes permet de relever les mots les plus fréquents dans un fichier. Pour cela, le code suivant est utilisé:

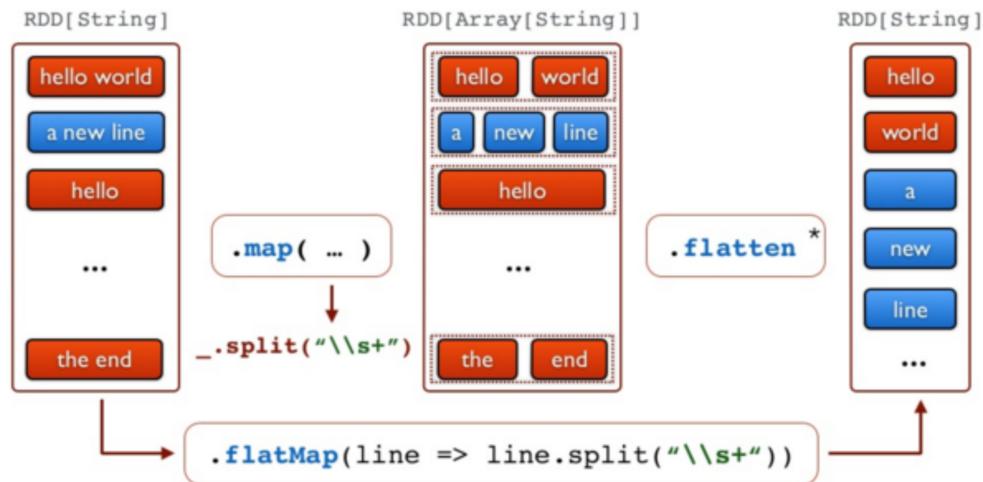
```
//Etape 1 - Créer un RDD à partir d'un fichier texte de Hadoop
val docs = spark.textFile("/docs")
```



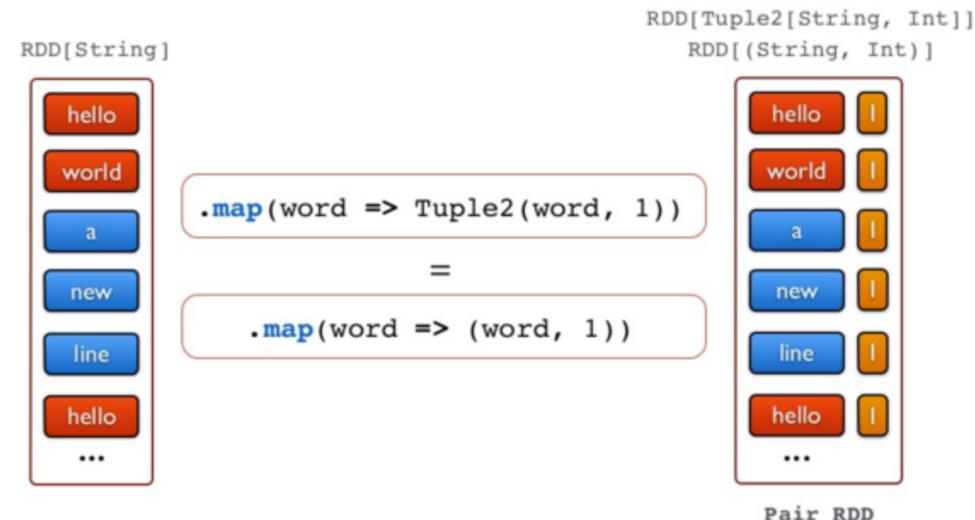
```
//Etape 2 - Convertir les lignes en minuscule  
val lower = docs.map(line => line.toLowerCase)
```



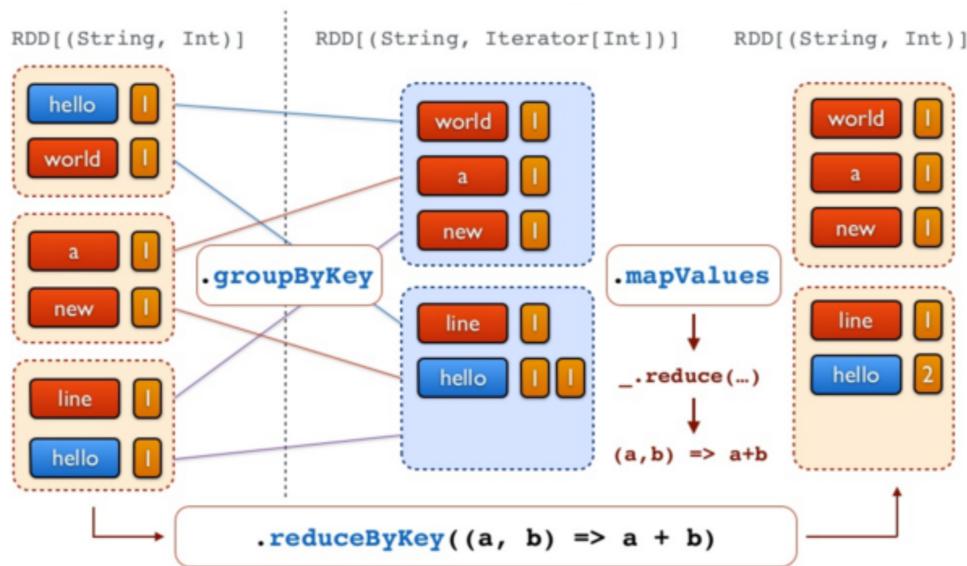
```
//Etape 3 - Séparer les lignes en mots  
val words = lower.flatMap(line => line.split("\\s+"))
```



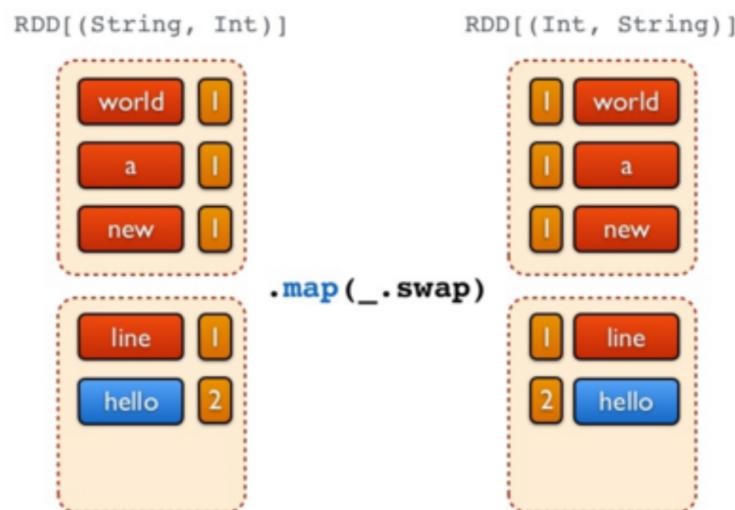
```
//Etape 4 - produire les tuples (mot, 1)
val counts = words.flatMap(word => (word, 1))
```



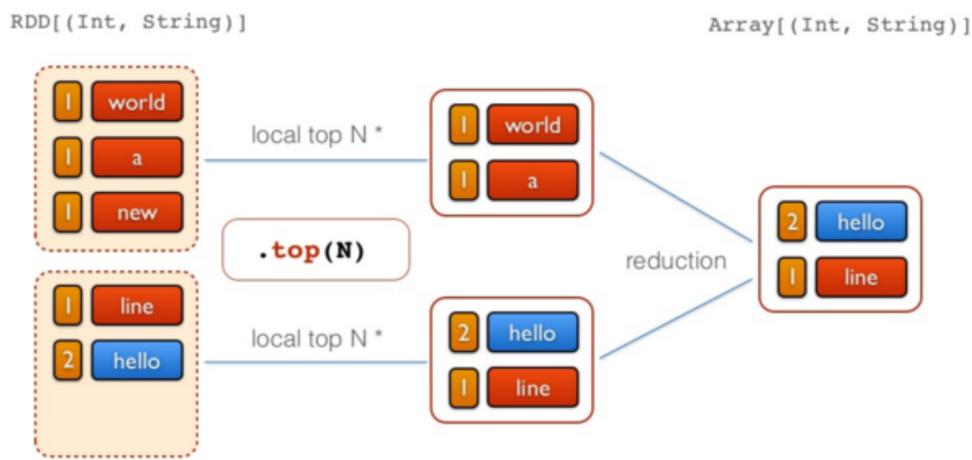
```
//Etape 5 - Compter tous les mots
val freq = counts.reduceByKey(_ + _)
```



```
//Etape 6 - Inverser les tuples (transformation avec swap)
freq.map(_.swap)
```



```
//Etape 6 - Inverser les tuples (action de sélection des n premiers)
val top = freq.map(_.swap).top(N)
```



Spark Batch en Java

Préparation de l'environnement et Code

Nous allons dans cette partie créer un projet Spark Batch en Java (un simple WordCount), le charger sur le cluster et lancer le job.

1. Créer un projet Maven avec IntelliJ IDEA, en utilisant la config suivante:

```
<groupId>spark.batch</groupId>
<artifactId>wordcount</artifactId>
<version>1</version>
```

2. Rajouter dans le fichier pom les dépendances nécessaires, et indiquer la version du compilateur Java:

```
<properties>
    <maven.compiler.source>1.8</maven.compiler.source>
    <maven.compiler.target>1.8</maven.compiler.target>
</properties>
<dependencies>
    <dependency>
        <groupId>org.apache.spark</groupId>
        <artifactId>spark-core_2.11</artifactId>
        <version>2.1.0</version>
```

```
</dependency>
<dependency>
    <groupId>org.slf4j</groupId>
    <artifactId>slf4j-log4j12</artifactId>
    <version>1.7.22</version>
</dependency>
</dependencies>
```

3. Sous le répertoire java, créer un package que vous appellerez *tn.insat.tp21*, et dedans, une classe appelée *WordCountTask*.

4. Écrire le code suivant dans *WordCountTask*:

```
public class WordCountTask {
    private static final Logger LOGGER = LoggerFactory.getLogger(WordCountTask.class);

    public static void main(String[] args) {
        checkArgument(args.length > 1, "Please provide the path to the input file");
        new WordCountTask().run(args[0], args[1]);
    }

    public void run(String inputFilePath, String outputDir) {
        String master = "local[*]";
        SparkConf conf = new SparkConf()
            .setAppName(WordCountTask.class.getName())
            .setMaster(master);
        JavaSparkContext sc = new JavaSparkContext(conf);

        JavaRDD<String> textFile = sc.textFile(inputFilePath);
        JavaPairRDD<String, Integer> counts = textFile
            .flatMap(s -> Arrays.asList(s.split(" "))).iterator()
            .mapToPair(word -> new Tuple2<>(word, 1))
            .reduceByKey((a, b) -> a + b);
        counts.saveAsTextFile(outputDir);
    }
}
```

La première chose à faire dans un programme Spark est de créer un objet *JavaSparkContext*, qui indique à Spark comment accéder à un cluster. Pour créer ce contexte, vous aurez besoin de construire un objet *SparkConf* qui contient toutes les informations sur l'application.

- *appName*: est de nom de l'application
- *master* est une URL d'un cluster Spark, Mesos ou YARN, ou bien une chaîne spéciale *local* pour lancer le job en mode local.



Warning

Nous avons indiqué ici que notre master est *local* pour les besoins du test, mais plus tard, en le packageant pour le cluster, nous allons enlever cette indication. Il est en effet déconseillé de la hard-coder dans le programme, il faudrait plutôt l'indiquer comme option de commande à chaque fois que nous lançons le job.

Le reste du code de l'application est la version en Java de l'exemple en scala que nous avions fait avec spark-shell.

Test du code en local

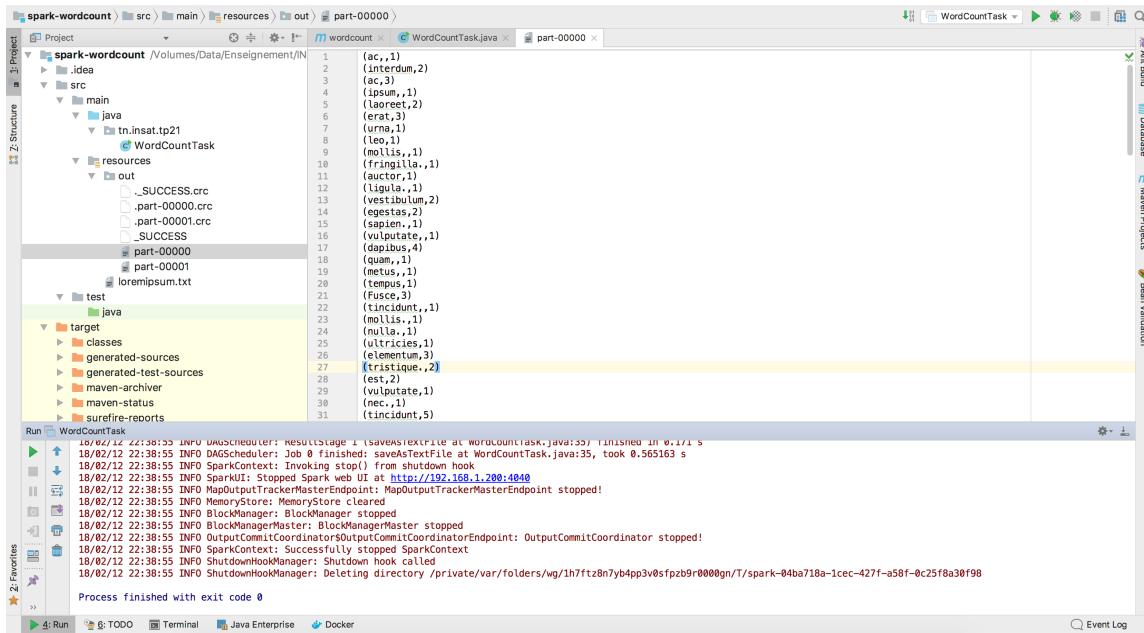
Pour tester le code sur votre machine, procéder aux étapes suivantes:

1. Insérer un fichier texte de votre choix (par exemple le fameux [lorem ipsum.txt](https://s3-eu-west-1.amazonaws.com/insat.lilia.bigdata.bucket/data/lorem ipsum.txt) [<https://s3-eu-west-1.amazonaws.com/insat.lilia.bigdata.bucket/data/lorem ipsum.txt>]) dans le répertoire src/main/resources.
2. Créer une nouvelle configuration de type "Application" (*Run->Edit Configurations*) que vous appellerez *WordCountTask*, et définir les arguments suivants (fichier de départ et répertoire d'arrivée) comme *Program arguments*:

```
src/main/resources/lorem ipsum.txt src/main/resources/out
```



3. Cliquer sur OK, et lancer la configuration. Si tout se passe bien, un répertoire *out* sera créé sous *resources*, qui contient deux fichiers: part-00000, part-00001.



Lancement du code sur le cluster

Pour exécuter le code sur le cluster, modifier comme indiqué les lignes en jaune dans ce qui suit:

```

public class WordCountTask {
    private static final Logger LOGGER = LoggerFactory.getLogger(WordCountTask.class);

    public static void main(String[] args) {
        checkArgument(args.length > 1, "Please provide the path of input file");
        new WordCountTask().run(args[0], args[1]);
    }

    public void run(String inputFilePath, String outputDir) {
        SparkConf conf = new SparkConf()
            .setAppName(WordCountTask.class.getName());

        JavaSparkContext sc = new JavaSparkContext(conf);

        JavaRDD<String> textFile = sc.textFile(inputFilePath);
        JavaPairRDD<String, Integer> counts = textFile
            .flatMap(s -> Arrays.asList(s.split("\t")).iterator())
            .mapToPair(word -> new Tuple2<>(word, 1))
            .reduceByKey((a, b) -> a + b);
    }
}

```

```
    counts.saveAsTextFile(outputDir);  
}
```

Lancer ensuite une configuration de type Maven, avec les commandes `package install`. Un fichier intitulé `worcount-1.jar` sera créé sous le répertoire target.

Nous allons maintenant copier ce fichier dans docker. Pour cela, naviguer vers le répertoire du projet avec votre terminal (ou plus simplement utiliser le terminal dans IntelliJ), et taper la commande suivante:

```
docker cp target/wordcount-1 hadoop-master:/root/wordcount-1.jar
```

Revenir à votre conteneur master, et lancer un job Spark en utilisant ce fichier jar généré, avec la commande `spark-submit`, un script utilisé pour lancer des applications spark sur un cluster.

```
spark-submit --class tn.insat.tp21.WordCountTask  
            --master local  
            --driver-memory 4g --executor-memory 2g --executor-c  
wordcount.jar  
            input/purchases.txt  
            output
```

- Nous allons lancer le job en mode local, pour commencer.
- Le fichier en entrée est le fichier purchases.txt (que vous trouverez déjà chargé sur le conteneur master), et le résultat sera stocké dans un répertoire `output`.



Attention

Vérifiez bien que le fichier `purchases` existe dans le répertoire input de HDFS, et que le répertoire `output` n'existe pas!

Si tout se passe bien, vous devriez trouver, dans le répertoire `output`, deux fichiers part-00000 et part-00001, qui ressemblent à ce qui suit:

```
root@hadoop-master:~# more output/part-00000
(166.92,82)
(116.84,86)
(379.92,78)
(411.79,95)
(487.01,72)
(4.24,75)
(326.52,88)
(384.14,74)
(244.04,85)
(144.96,89)
(416.65,76)
(489.03,71)
(383.73,97)
(250.61,74)
(36.01,78)
(367.86,80)
(86.95,78)
(88.99,81)
(30.27,87)
(195.87,77)
(473.46,96)
(80.53,83)
(232.85,61)
```

Nous allons maintenant tester le comportement de `spark-submit` si on l'exécute en mode *cluster* sur YARN. Pour cela, exécuter le code suivant:

```
spark-submit --class tn.insat.tp21.WordCountTask
             --master yarn
             --deploy-mode cluster
             --driver-memory 4g --executor-memory 2g --executor-c
wordcount.jar
             input/purchases.txt
             output2
```

- En lançant le job sur Yarn, deux modes de déploiement sont possibles:
 - Mode cluster: où tout le job s'exécute dans le cluster, c'est à dire les Spark Executors (qui exécutent les vraies tâches) et le Spark Driver (qui ordonne les Executors). Ce dernier sera encapsulé dans un YARN Application Master.
 - Mode client : où Spark Driver s'exécute sur la machine cliente (tel que votre propre ordinateur portable). Si votre machine s'éteint, le job s'arrête. Ce mode est approprié pour les jobs interactifs.

Si tout se passe bien, vous devriez obtenir un répertoire output2 dans HDFS avec les fichiers usuels.



Erreur

En cas d'erreur ou d'interruption du job sur Yarn, vous pourrez consulter les fichiers logs pour chercher le message d'erreur (le message affiché sur la console n'est pas assez explicite). Pour cela, sur votre navigateur, aller à l'adresse: <http://localhost:8041/logs/userlogs> et suivez toujours les derniers liens jusqu'à `stderr`.

Spark Streaming

Spark est connu pour supporter également le traitement des données en streaming. Les données peuvent être lues à partir de plusieurs sources tel que Kafka, Flume, Kinesis ou des sockets TCP, et peuvent être traitées en utilisant des algorithmes complexes. Ensuite, les données traitées peuvent être stockées sur des systèmes de fichiers, des bases de données ou des dashboards. Il est même possible de réaliser des algorithmes de machine learning et du traitement de graphes sur les flux de données.



En interne, il fonctionne comme suit. Spark Streaming reçoit des données en streaming et les divise en micro-batches, qui sont ensuite calculés par le moteur de spark pour générer le flux final de résultats.



Environnement et Code

Nous allons commencer par tester le streaming en local, comme d'habitude.

Pour cela:

1. Commencer par créer un nouveau projet Maven, avec le fichier pom suivant:

```
<?xml version="1.0" encoding="UTF-8"?>
<project xmlns="http://maven.apache.org/POM/4.0.0"
          xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
          xsi:schemaLocation="http://maven.apache.org/POM/4.0.0 http://maven.apache.org/xsd/maven-4.0.0.xsd">
    <modelVersion>4.0.0</modelVersion>

    <groupId>spark.streaming</groupId>
    <artifactId>stream</artifactId>
    <version>1</version>

    <dependencies>
        <dependency>
            <groupId>org.apache.spark</groupId>
            <artifactId>spark-core_2.11</artifactId>
            <version>2.2.1</version>
        </dependency>
        <dependency>
            <groupId>org.apache.spark</groupId>
            <artifactId>spark-streaming_2.11</artifactId>
            <version>2.2.1</version>
        </dependency>
    </dependencies>
    <build>
        <plugins>
            <plugin>
                <groupId>org.apache.maven.plugins</groupId>
                <artifactId>maven-compiler-plugin</artifactId>
                <version>3.1</version>
                <configuration>
                    <source>1.8</source>
                    <target>1.8</target>
                </configuration>
            </plugin>
        </plugins>
    </build>
```

```
</project>
```

2. Créer une classe *tn.insat.tp22.Stream* avec le code suivant:

```
public class Stream {  
    public static void main(String[] args) throws InterruptedException {  
        SparkConf conf = new SparkConf()  
            .setAppName("NetworkWordCount")  
            .setMaster("local");  
        JavaStreamingContext jssc =  
            new JavaStreamingContext(conf, Durations.seconds(1));  
  
        JavaReceiverInputDStream<String> lines =  
            jssc.socketTextStream("localhost", 9999);  
  
        JavaDStream<String> words =  
            lines.flatMap(x -> Arrays.asList(x.split(" "))).iterator();  
        JavaPairDStream<String, Integer> pairs =  
            words.mapToPair(s -> new Tuple2<>(s, 1));  
        JavaPairDStream<String, Integer> wordCounts =  
            pairs.reduceByKey((i1, i2) -> i1 + i2);  
  
        wordCounts.print();  
        jssc.start();  
        jssc.awaitTermination();  
    }  
}
```

Ce code permet de calculer le nombre de mots dans un stream de données toutes les secondes.

Test du code en Local

Le stream ici sera diffusé par une petite commande utilitaire qui se trouve dans la majorité des systèmes Unix-like.

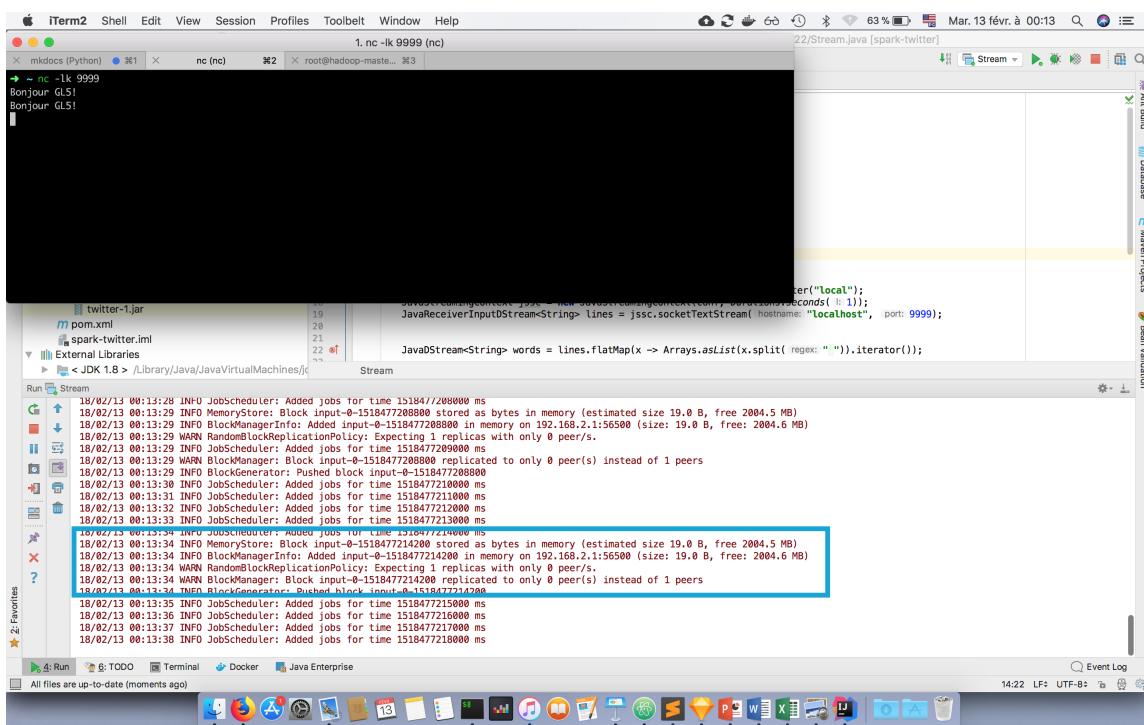
- Ouvrir un terminal, et taper la commande suivante pour créer le stream:

```
nc -lk 9999
```

Vous pourrez alors taper les entrées de votre choix.

- Exécuter votre classe Stream. Vous verrez défiler sur votre console des lignes en continu: l'application est en écoute sur localhost:9999.

A chaque fois que vous entrez quelque chose sur le terminal, l'application l'intercepte, et l'affichage sur l'écran de la console change, comme suit:



```

18/02/13 08:13:28 INFO JobScheduler: Added jobs for time 1518477208000 ms
18/02/13 08:13:29 INFO MemoryStore: Block input-0-1518477208000 stored as bytes in memory (estimated size 19.0 B, free 2004.5 MB)
18/02/13 08:13:29 INFO BlockManagerInfo: Added input-0-1518477208000 in memory on 192.168.2.1:56500 (size: 19.0 B, free: 2004.6 MB)
18/02/13 08:13:29 WARN RandomBlockReplicationPolicy: Expecting 1 replicas with only 0 peer/s.
18/02/13 08:13:29 INFO JobScheduler: Added jobs for time 1518477209000 ms
18/02/13 08:13:29 WARN BlockManager: Block input-0-1518477209000 replicated to only 0 peer(s) instead of 1 peers
18/02/13 08:13:29 INFO JobScheduler: Added jobs for time 1518477209000 ms
18/02/13 08:13:29 INFO BlockManager: Block input-0-1518477209000 replicated to only 0 peer(s) instead of 1 peers
18/02/13 08:13:30 INFO JobScheduler: Added jobs for time 1518477210000 ms
18/02/13 08:13:31 INFO JobScheduler: Added jobs for time 1518477211000 ms
18/02/13 08:13:32 INFO JobScheduler: Added jobs for time 1518477212000 ms
18/02/13 08:13:33 INFO JobScheduler: Added jobs for time 1518477213000 ms
18/02/13 08:13:34 INFO JobScheduler: Added jobs for time 1518477214000 ms
18/02/13 08:13:34 INFO MemoryStore: Block input-0-1518477214000 stored as bytes in memory (estimated size 19.0 B, free 2004.5 MB)
18/02/13 08:13:34 INFO BlockManagerInfo: Added input-0-1518477214000 in memory on 192.168.2.1:56500 (size: 19.0 B, free: 2004.6 MB)
18/02/13 08:13:34 WARN RandomBlockReplicationPolicy: Expecting 1 replicas with only 0 peer/s.
18/02/13 08:13:34 INFO BlockManager: Block input-0-1518477214000 replicated to only 0 peer(s) instead of 1 peers
18/02/13 08:13:34 INFO BlockGenerator: Pushed block input-0_1518477214000
18/02/13 08:13:35 INFO JobScheduler: Added jobs for time 1518477215000 ms
18/02/13 08:13:36 INFO JobScheduler: Added jobs for time 1518477216000 ms
18/02/13 08:13:37 INFO JobScheduler: Added jobs for time 1518477217000 ms
18/02/13 08:13:38 INFO JobScheduler: Added jobs for time 1518477218000 ms

```

Ensuite, pour voir le résultat final du comptage, arrêter l'exécution en cliquant sur le carré rouge, puis observer la console, vous verrez un affichage qui ressemble à ceci:

The screenshot shows the IntelliJ IDEA interface with the project 'spark-twitter' open. The code editor displays 'Stream.java' with the following content:

```

1 package tn.insat.tp2;
2
3 import org.apache.spark.SparkConf;
4 import org.apache.spark.streaming.Durations;
5 import org.apache.spark.streaming.api.java.JavaDStream;
6 import org.apache.spark.streaming.api.java.JavaPairDStream;
7 import org.apache.spark.streaming.api.java.JavaReceiverInputDStream;
8 import org.apache.spark.streaming.api.java.JavaStreamingContext;
9 import scala.Tuple2;
10
11 import java.util.Arrays;
12
13
14 public class Stream {
15     public static void main(String[] args) throws InterruptedException {
16         SparkConf conf = new SparkConf().setAppName("NetworkWordCount").setMaster("local");
17         JavaStreamingContext jssc = new JavaStreamingContext(conf, Durations.seconds(1));
18         JavaReceiverInputDStream<String> lines = jssc.socketTextStream("localhost", 9999);
19     }
20 }

```

The terminal window below shows the execution logs:

```

18/02/13 08:13:51 INFO TaskSetManager: Starting task 0.0 in stage 34.0 (TID 19, localhost, executor driver, partition 0, ANY, 4621 bytes)
18/02/13 08:13:51 INFO Executor: Running task 0.0 in stage 34.0 (TID 19)
18/02/13 08:13:51 INFO ShuffleBlockFetcherIterator: Getting 1 non-empty blocks out of 1 blocks
18/02/13 08:13:51 INFO Executor: Started 0 remote fetches in 0 ms
18/02/13 08:13:51 INFO ShuffleBlockFetcherIterator: Started 0 remote fetches in 0 ms
18/02/13 08:13:51 INFO Executor: Finished task 0.0 in stage 34.0 (TID 19). 1261 bytes result sent to driver
18/02/13 08:13:51 INFO TaskSetManager: Finished TaskSet 34.0, whose tasks have all completed, from pool
18/02/13 08:13:51 INFO TaskSchedulerImpl: Removed TaskSet 34.0, whose tasks have all completed, from pool
18/02/13 08:13:51 INFO DAGScheduler: Job 11 finished: print at Stream.java:27 took 0.07463 s
18/02/13 08:13:51 INFO DAGScheduler: Job 11 finished: print at Stream.java:27 took 0.07463 s
18/02/13 08:13:51 INFO DAGScheduler: Finished job streaming job 1518477215000 ms.0 from job set of time 1518477215000 ms
18/02/13 08:13:51 INFO DAGScheduler: Total delay: 16.173 s for time 1518477215000 ms (execution: 0.032 s)
18/02/13 08:13:51 INFO JobScheduler: Starting job streaming job 1518477216000 ms.0 from job set of time 1518477216000 ms
Time: 1518477215000 ms
-----
(GL5,1)
(Bonjour,1)

18/02/13 08:13:51 INFO SparkContext: Starting job: print at Stream.java:27
18/02/13 08:13:51 INFO DAGScheduler: Registering RDD 73 (mapToPair at Stream.java:24)
18/02/13 08:13:51 INFO DAGScheduler: Got job 18 (print at Stream.java:27) with 1 output partitions
18/02/13 08:13:51 INFO DAGScheduler: Final stage: ResultStage 36 (print at Stream.java:27)
18/02/13 08:13:51 INFO DAGScheduler: Parents of final stage: List[ResultStage 35]
18/02/13 08:13:51 INFO DAGScheduler: Submitting ResultStage 36 (ShuffledRDD[72] at reduceByKey at Stream.java:25), which has no missing parents
18/02/13 08:13:51 INFO DAGScheduler: Block broadcast_29 stored as values in memory (estimated size 3.7 KB, free 2094.5 MB)

```

Lancement du code sur le cluster

Pour lancer le code précédent sur le cluster, il faudra d'abord faire des petites modifications:



Attention

Veillez à mettre l'IP de votre machine locale (sur laquelle vous allez lancer le flux avec nc) à la place de <votre-ip>. Vous pourrez trouver votre IP avec la commande ifconfig.

- Lancer un mvn package install pour créer le fichier jar.
- Copier le fichier jar sur le conteneur hadoop.
- Lancer la commande suivante:

```
spark-submit --class tn.insat.tp2.Stream
--master local
--driver-memory 4g --executor-memory 2g --executor-memory 2g
stream-1.jar
```

Observer le résultat.

Homework

Vous allez, pour ce cours, réaliser un projet en binôme, qui consiste en la construction d'une architecture Big Data supportant le streaming, le batch processing, et le dashboarding temps réel. Pour la séance prochaine, vous allez réfléchir au type de traitement que vous voulez réaliser (le flux de données en entrée, et les résultats en sortie). Vous allez commencer par utiliser Spark pour réaliser ces traitements, avec un stockage sur HDFS au besoin.

